Homework

Ricci Flavia, Migliarini Matteo Metodi probabilistici per l'informatica

June 12, 2022

1 Esercizio 1

A) <u>Passo base</u> (t=k): L'unico S_k possibile è N_k , quindi $P(S_k = X) = P(S_k = N_k) = 1 = {t \choose k}^{-1} = {k \choose k}^{-1} = 1$. La proprietà è verificata.

<u>Passo induttivo</u> (t>k): Per ipotesi induttiva sappiamo che S_{t-1} è un sottoinsieme estratto u.a.r. da N_{t-1} . Si possono verificare due casi:

- l'elemento nuovo è salvato, ossia S_k e S_{k-1} differiscono per un elemento (prob. $=\frac{k}{t}$);
- l'elemento nuovo è scartato, ossia S_k e S_{k-1} sono uguali (prob. $=\frac{t-k}{t}$).

Sia X un generico insieme di k elementi tale che X \subset N_t, e sia \hat{X} un insieme che differisce da X per uno specifico elemento. Nel primo caso si ha che:

$$\mathbb{P}(S_t = X \cap S_{t-1} = X) = [\text{teo. di Bayes}] \ \mathbb{P}(S_t = X | S_{t-1} = X) \cdot \mathbb{P}(S_{t-1} = X) = \frac{t-k}{t} \cdot {t-1 \choose k}^{-1} = {t \choose k}^{-1}$$

Per l'altro caso invece osserviamo che:

 $\mathbb{P}(S_t = X | S_{t-1} = \hat{X}) = [\text{prob. di sostituire} \times \text{prob.di scartare uno specifico elemento tra k}] \frac{k}{t} \cdot \frac{1}{k} = \frac{1}{t}$

e che il numero dei possibili \hat{X} è t-k. Infatti l'unico elemento variabile di \hat{X} (quello che sarà sostituito) può essere uno dei t-k elementi di $N_{k-1} \setminus \{\text{elementi fissi di } \hat{X}\}$. Quindi:

$$\mathbb{P}(S_t = X \cap S_{t-1} = \hat{X}) = \mathbb{P}(S_t = X | S_{t-1} = \hat{X}) \cdot \mathbb{P}(S_{t-1} = \hat{X}) = \frac{1}{t} \cdot (t - k) \cdot {t-1 \choose k}^{-1} = {t \choose k}^{-1}$$

Si ha $\mathbb{P}(S_t = X \cap S_{t-1} = X) = \mathbb{P}(S_t = X \cap S_{t-1} = X) = {t \choose k}^{-1}$. Dunque il fatto di differire o meno da S_{t-1} (ossia di contenere o meno l'ultimo elemento) non influisce sulla probabilità di osservarlo per cui: $\mathbb{P}(S_t = X) = \mathbb{P}(S_t = X \cap S_{t-1} = X) = \mathbb{P}(S_t = X \cap S_{t-1} = \hat{X}) = {t \choose k}^{-1}$

B) In generale sono dipendenti, ad esempio poichè S_t e S_{t+1} differiriscono al più per un elemento conoscendo S_t posso escludere di osservare alcuni S_{t+1} .

2 Esercizio 2

- **A)** Il tempo di percorrenza deve almeno permettere a c pacchetti di attraversare lo stesso arco, cosa che non può avvenire in meno di c tempi, e deve inoltre permettere a un pacchetto di attraversare d archi, cosa che non può avvenire in meno di d tempi. Per cui esso è almeno $max(c,d) \ge \frac{1}{2}(c+d) = \Omega(c+d)$.
- **B)** Assumiamo ragionevolmente che un pacchetto passi al più una volta sullo stesso arco. Sia $X_{e,t}$ il numero di pacchetti su e al tempo t. Sia dunque $k = \lceil \frac{\alpha c}{\log(Nd)} \rceil$ e $\mathbb{P}(p)$ passa su e al tempo t) $\leq \frac{1}{k}$ (l'evento può verificarsi solo se il pacchetto parte a un ben preciso istante).

Definiamo $Y_{e,t,p} \sim Bern(\frac{1}{k})$, allora $\sum_{p \in P}^{c} Y_{e,t,p} = X_{e,t} \sim Binomial(c, \frac{1}{k})$

$$\mathbb{P}(X_{e,t} > O(\log(Nd))) =$$

 $\mathbb{P}(\text{almeno }O(\log(Nd))$ pacchetti passano su eal tempo t
) × (combinazioni di $O(\log(Nd))$ pacchetti tra c

$$\leq \binom{c}{O(\log(Nd))} (\frac{O(\log(Nd))}{\alpha c})^{O\log(Nd)} \leq [\text{dis. di Stirling}] (\frac{ce}{O(\log(Nd))})^{O(\log(Nd))} (\frac{O(\log(Nd))}{\alpha c})^{O\log(Nd)}$$

$$= (\frac{e}{\alpha})^{O(\log(Nd))}$$

- C) Ogni pacchetto percorre al più d archi, quindi il numero totale degli attraversamenti è al più Nd. Utilizzando union bound sulla formula del punto b, si ottiene: $\mathbb{P}(anyX > O(\log(Nd))) \leq (\frac{e}{\alpha})^{O(\log(Nd))} \cdot Nd$ che vogliamo sia $<(\frac{1}{Nd})$. La disuguaglianza è soddisfatta se $\alpha > e \cdot (Nd)^{\frac{2}{O(\log(Nd))}} = e \cdot 2^{\frac{2 \cdot \log(Nd)}{O(\log(Nd))}} = e \cdot 2^{O(1)} = O(1)$.
- **D)** Sia P l'insieme dei pacchetti, $path_i$ e $start_i$ rispettivamente il percorso e il nodo d'inizio del pacchetto i-esimo.

Algorithm 1 Scheduling(P: piano orario originale)

```
\begin{split} N &\leftarrow |P| \\ d &\leftarrow max\{l: \forall p \in P, l = |path_p|\} \\ c &\leftarrow max\{c_e: c_e = |e \in path_p|, \forall p \in P\} \\ \textbf{for } p &\in P \textbf{ do} \\ delay_p &\leftarrow random_between(1, \lceil \frac{50 \cdot c}{\log Nd} \rceil) \\ prefix_p &\leftarrow \operatorname{list}[start_p, ..., start_p] \text{ per } delay_p \text{ volte} \\ path_p &\leftarrow path_p \text{ ma preceduto da } prefix_p \\ \textbf{end for} \\ \textbf{return } \text{ il nuovo } P \end{split}
```

Come dimostrato in (c) la proabilità che più di $O(\log(Nd))$ vogliano attraversare un certo arco in un certo momento t è al più $\frac{1}{Nd}$, ergo anche la probabilità che si creino code più lunghe di tale cifra è bassa in N. Nel caso peggiore ogni pacchetto dovrà percorrere al massimo una distanza d più il ritardo massimo $\lceil \frac{\alpha \cdot c}{\log Nd} \rceil$, e visto che ora bisogna rispettare il vincolo sugli archi, ogni pacchetto potrebbe dover aspettare al massimo per $O(\log Nd)$ per ogni suo step.

$$O(\log(Nd) \cdot (\lceil \frac{\alpha \cdot c}{\log Nd} \rceil + d)) = O(\alpha \cdot c + d \cdot \log(Nd)) = O(c + d \log(Nd))$$

3 Esercizio 3

A)

Ad ogni passo la lista si riduce di almeno un elemento (il pivot) e dunque l'algoritmo termina. Dimostriamo che le riduzioni applicate sono corrette:

<u>Caso i = k-1</u>: Assumiamo per assurdo che il pivot non sia il k-esimo elemento più grande. In tal caso il k-esimo elemento dovrebbe trovarsi in S_1 o in S_2 , ma S_1 per costruzione contiene i primi k-1 elementi, quindi non può contenere il k-esimo e sempre per costruzione S_2 contiene solo elementi più grandi di tutti i k-1 elementi di S_1 e del pivot, ossia più grandi di almeno altri k elementi e dunque non può contenere il k-esimo. Caso i \geq k: Per costruzione S_1 contiene i primi i elementi e poiché i \geq k tra questi primi i elementi ci sta anche il k-esimo, che (sempre per costruzione) coincide con il k-esimo elemento di S_1 .

<u>Caso i<k-1</u>: Per costruzione S_1 non contiene il k-esimo elemento. Il pivot, essendo l'elemento immediatamente più grande degli elementi di S_1 , è al più il (k-1)-esimo. Quindi il k-esimo elemento non può che stare in S_2 . In particolare poichè S_2 è l'insieme di partenza da cui sono stati eliminati i primi i+1 elementi, il k-esimo elemento dell'insieme di partenza coincide con il (k-i-1)-esimo di S_2 .

- B) Il caso peggiore è quello con più ricorsioni e più confronti a ricorsione, ossia quello in cui il pivot è sempre un estremo. In tal caso $N=n+(n-1)+(n-2)+...+1=[\text{somm. di Gauss}] \frac{n(n+1)}{2}=O(n^2)$.
 C) Definiamo una chiamata di successo come una chiamata che ha il pivot nel terzo mediano di S (di successo
- C) Definiamo una chiamata di successo come una chiamata che ha il pivot nel terzo mediano di S (di successo perché ci garantisce che la dimensione della lista su cui ricorrere sia contenuta entro un certo valore). Si ha che $P(Successo) = \frac{1}{3}$.

Sia n := |S iniziale|, dopo i successi $|S| \le n(\frac{2}{3})^i$. Poiché l'algoritmo termina quando $|S| \le 1$, termina quando $i \le \log_{\frac{3}{2}}$ n. Sia $T_i = \#$ iterazioni tra l'i-esimo e l'(i+1)-esimo successo. Si ha che $T_i \sim \text{Geom}(1/3)$, per cui $\text{E}[T_i] = 3$.

$$N = \sum_{i=0}^{\text{successi per terminare}} \text{confronti per successo} \Rightarrow [\text{linearità del valore atteso}]$$

$$\mathbb{E}[N] = \sum_{i=0}^{\text{successi per terminare}} E[\text{confronti per successo}] \leq \sum_{i=0}^{\text{successi per terminare}} (|\text{S all'i-esimo successo}|) \mathbb{E}[T_i] = \sum_{i=0}^{\text{logs, pr}} E[\text{confronti per successo}] \leq \sum_{i=0}^{\text{successi per terminare}} (|\text{S all'i-esimo successo}|) \mathbb{E}[T_i] = \sum_{i=0}^{\text{logs, pr}} E[\text{confronti per successo}] \leq \sum_{i=0}^{\text{successi per terminare}} (|\text{S all'i-esimo successo}|) \mathbb{E}[T_i] = \sum_{i=0}^{\text{logs, pr}} E[\text{confronti per successo}] \leq \sum_{i=0}^{\text{successi per terminare}} (|\text{S all'i-esimo successo}|) \mathbb{E}[T_i] = \sum_{i=0}^{\text{logs, pr}} E[\text{confronti per successo}] \leq \sum_{i=0}^{\text{successi per terminare}} (|\text{S all'i-esimo successo}|) \mathbb{E}[T_i] = \sum_{i=0}^{\text{logs, pr}} E[\text{confronti per successo}] = \sum_{i=0}^{\text{logs, pr}} E[\text{confronti per$$

$$\leq \sum_{i=0}^{\log_{\frac{3}{2}}n} n(\frac{2}{3})^i 3 \leq 3n \sum_{i=0}^{\infty} (\frac{2}{3})^i = [\text{serie geometrica}] \ 3n \frac{1}{1-\frac{2}{3}} < 9n = O(n)$$

D) Per la disuguaglianza di Markov: $\mathbb{P}(N \geq a \cdot O(n)) \leq \frac{\mathbb{E}[N]}{a \cdot O(n)} = O(\frac{n}{a \cdot n}) \leq O(\frac{1}{a})$

Per ogni a di ordine di grandezza maggiore di O(1), quando $n \to \infty$ la probabilità converge a 0. Perciò ad esempio se ci chiediamo quale sia la probabilità che l'algoritmo impieghi un tempo quadratico, allora a = O(n), $\mathbb{P}(N \ge O(n^2)) \le O(\frac{1}{n})$ che per $n \to \infty$ converge a 0.

4 Esercizio 4

A)

Algorithm 2 ClusteringCoefficient(V, E)

```
\begin{array}{l} C_G \leftarrow 0 \\ n \leftarrow |V| \\ \textbf{for } v \in V \ \textbf{do} \\ N_v \leftarrow N(v) \\ C_v \leftarrow 0 \\ \#coppie \leftarrow \binom{|N_v|}{2} \\ \textbf{for } \{u,w\} \in N_v \times N_v \ \textbf{do} \\ \textbf{if } \{u,w\} \in E \ \textbf{then} \\ C_v \leftarrow C_v + \frac{1}{\#coppie} \\ \textbf{end if} \\ \textbf{end for} \\ C_G \leftarrow C_G + \frac{C_v}{n} \\ \textbf{end for} \\ \textbf{return } C_G \end{array}
```

Siano n = |V| e m = |E| allora il costo asintotico di questo algoritmo è $O(n(m + mn^2)) = O(n^3m)$ usando una rappresentazione con liste e $O(n^3)$ usando una matrice di adiacenza. Il caso peggiore è quando tutti i nodi hanno un arco verso tutti gli altri nodi (tutti i nodi sono vicini tra loro e $C_G = 1$).

B)

Per come è organizzato l'algoritmo, X_i è una variabile aleatoria di tipo Bernoulliano, $X_i \sim Bern(p)$. Infatti con una certa probabilità essa assume valore 1, o altrimenti 0. Ma quale è questa probabilità?

$$p = \mathbb{P}(\{u, w\} \in E | u \in N(v) \land w \in N(v))$$

Perché appunto ad X_i viene assegnato il valore 1 se u e w sono connessi da un arco, sapendo che u e w sono stati estratti uniformemente a caso da N(v). Perciò per il teorema di Bayes sulla probabilità condizionata:

$$\mathbb{P}(\{u,w\} \in E | u \in N(v) \land w \in N(v)) = \frac{\mathbb{P}(\{u,w\} \in E \land u \in N(v) \land w \in N(v))}{\mathbb{P}(u \in N(v) \land w \in N(v))} =$$

$$= \frac{\frac{|\{\{u,w\} \in E \land u \in N(v) \land w \in N(v)\}|}{\text{tutte le possibili coppie di nodi}}}{\frac{\text{tutte le possibili coppie di nodi tra i vicini di } v}{\text{tutte le possibili coppie di nodi}} = \frac{|\{\{u,w\} \in E \land u \in N(v) \land w \in N(v)\}|}{\text{tutte le possibili coppie di nodi tra i vicini di } v} =$$

$$= \frac{|\{\{u,w\} \in E \land u \in N(v) \land w \in N(v)\}|}{\binom{|N(v)|}{2}} = C_v$$

Ora, sappiamo che $X_i \sim Bern(p)$ con $p \sim Uniform(C_v)$. Allora:

$$X = \frac{1}{l} \sum_{i=0}^{l} X_i = \frac{1}{l} \sum_{i=0}^{l} Bern(Uniform(C_v)) = Bern(Uniform(C_v))$$

 $\mathbb{E}[X] = \mathbb{E}[Bern(Uniform(C_v))] = \mathbb{E}[Uniform(C_v)] = E[X_i] = [\text{val. att. dell'uniforme}] \text{ media di}(C_v) := C_G$

$$\mathbb{P}((1-\epsilon)C_G \le X \le (1+\epsilon)C_G) = \mathbb{P}(-\epsilon C_G \le X - C_G \le \epsilon C_G) = \mathbb{P}(|X - C_G| \le \epsilon C_G) = \mathbb{P}(|\sum_{i=0}^{l} X_i - lC_G| \le \epsilon lC_G) \ge 1 - \delta$$

E ora basta applicare il metodo Montecarlo, sapendo che $\mathbb{E}[X] = C_G$ e $W_l = lX = \sum_{i=0}^l X_i$

$$\mathbb{P}(|W_l - lC_G| \ge l\epsilon C_G) = \mathbb{P}(|W_l - \mathbb{E}[W_l]| \ge \epsilon \mathbb{E}[W_l]) = \mathbb{P}(W_l - \mathbb{E}[W_l] \ge \epsilon \mathbb{E}[W_l]) + \mathbb{P}(W_l - \mathbb{E}[W_l] \le \epsilon \mathbb{E}[W_l]) =$$

$$\le [\text{dis. di Chernoff}] e^{-\frac{1}{3}\epsilon^2 \mathbb{E}[W_l]} + e^{-\frac{1}{2}\epsilon^2 \mathbb{E}[W_l]} < 2e^{-\frac{1}{3}\epsilon^2 \mathbb{E}[W_l]} = 2e^{-\frac{1}{3}\epsilon^2 lC_G} \le \delta \Rightarrow l \ge \frac{3}{\epsilon^2 C_G} ln \frac{2}{\delta}$$